

Informe - workshop 003

Juan Esteban Paredes-Álvarez

Programa de ingeniería de datos e inteligencia artificial.

Facultad de ingeniería y ciencias básicas.

Universidad Autónoma de Occidente

2026

Nota del autor

Juan Esteban Paredes-Álvarez, juan_esteban.paredes@uao.edu.co

Introducción:

El presente proyecto tuvo como objetivo desarrollar un pipeline ETL completo integrando procesamiento de datos, automatización, transmisión en tiempo real y Machine Learning para predecir el Happiness Score de países utilizando las fuentes de datos proporcionadas.

La solución fue construida utilizando tecnologías como:

Apache Airflow, Apache Kafka, Docker, MySQL, scikit-learn, Pandas, Matplotlib.

El flujo del pipeline fue el siguiente:

1. Ingesta de archivos CSV.
2. Conversión a formato Parquet.
3. Normalización de columnas.
4. Unión de datasets.
5. Entrenamiento del modelo de Machine Learning.
6. Serialización del modelo entrenado.
7. Transmisión del conjunto de prueba mediante Kafka.
8. Consumo de mensajes y generación de predicciones.
9. Carga de resultados en MySQL.
10. Visualización de métricas y resultados finales.

1. Descripción de los conjuntos de datos

Se utilizaron cinco archivos CSV de World Happiness Report de los años 2015, 2016, 2017, 2018 y 2019.

Cada archivo contenía información relacionada con indicadores sociales y económicos asociados al nivel de felicidad de distintos países.

Algunos archivos presentaban diferencia de nombres de columnas, entonces fue necesario realizar un proceso de normalización para unificar el esquema de datos.

El columnas a trabajar fueron:

```
["country", "year", "happiness_score", "economy", "family", "health", "freedom",  
"trust", "generosity"]
```

Las variables seleccionadas como features para el modelo fueron:

- economy
- family
- health
- freedom
- trust
- generosity

La variable que se buscaba predecir era:

- happiness_score

Además, durante la ingesta se agregó una columna correspondiente al año de cada fuente con el fin de mantener trazabilidad sobre el origen de los datos.

2. Principales conclusiones del análisis exploratorio de datos (EDA)

Durante el análisis exploratorio se realizaron distintas validaciones y procesos de inspección de calidad de datos como la detección de valores nulos, validación de valores fuera de rango, aunque no se encontraron registros significativamente fuera de rango. También se seleccionaron las variables relevantes basándose en investigaciones relacionadas con los factores principales que influyen en el índice de felicidad de los países. Las cuales fueron los seis features con los que se trabajaron

3. Selección del modelo y proceso de entrenamiento

Para el desarrollo del modelo predictivo se utilizó el algoritmo de regresión lineal múltiple utilizando la librería Scikit-learn.

El modelo fue seleccionado por:

La naturaleza numérica continua de la variable objetivo, la simplicidad e interpretabilidad del algoritmo y el tamaño relativamente reducido del dataset.

Proceso de entrenamiento

El dataset fue dividido en 70% para entrenamiento y 30% para pruebas y se plantó una semilla para garantizar la reproducibilidad de resultados.

Seguido de esto, se separaron variables predictoras y variable objetivo, se entrenó el modelo utilizando regresión lineal.

El modelo entrenado fue serializado en formato .pkl utilizando joblib.dump esto permitió reutilizar el modelo durante el proceso de streaming en Kafka.

Es importante resaltar que únicamente el conjunto de prueba fue enviado mediante Kafka, ya que el conjunto de entrenamiento ya había sido utilizado en la fase de aprendizaje.

4. Métricas de evaluación

El rendimiento del modelo fue evaluado utilizando:

MAE (Mean Absolute Error): 0.4245

Esta métrica indica que el error absoluto promedio entre los valores reales y las predicciones fue aproximadamente de 0.42 puntos en el Happiness Score.

RMSE (Root Mean Squared Error): 0.5454

El RMSE penaliza más fuertemente los errores grandes, por lo que el valor obtenido indica que el modelo mantiene una desviación relativamente controlada respecto a los datos reales.


R² (Coeficiente de determinación): 0.7598

El modelo logra explicar aproximadamente el 76% de la variabilidad de los datos utilizando las variables seleccionadas. Este muestra un ajuste adecuado considerando la simplicidad del modelo utilizado.

MAPE (Mean Absolute Percentage Error): 8.22%

El error porcentual promedio fue inferior al 10%, lo cual representa un desempeño aceptable.

Análisis gráfico:



En la gráfica de comparación entre valores reales y predicciones se observó una tendencia lineal clara y cercanía entre los puntos y la línea ideal de predicción.

Esto muestra que el modelo logró capturar correctamente gran parte del comportamiento de los datos.

5. Análisis del proceso de transmisión y resultados

El pipeline implementó el streaming utilizando Apache Kafka.

Kafka Producer fue encargado de:

Leer el dataset consolidado en formato Parquet, Aplicar la misma división de entrenamiento y prueba utilizada, transmitir únicamente el conjunto de prueba fila por fila al tópico:

happiness-predictions. La transmisión incluyó un retraso temporal entre mensajes para simular comportamiento streaming.

Kafka consumer:

El consumidor fue ejecutado manualmente desde el entorno local y cumple lo siguiente:

Consumir mensajes desde Kafka, cargar el modelo entrenado, generar predicciones en tiempo real, cargar resultados en MySQL.

Las predicciones fueron cargadas con los valores reales para facilitar el análisis y la visualización de métricas.

Resultados del streaming:

Se transmitieron y cargaron 235 registros, cada uno con sus respectivas predicciones y fueron almacenadas en la base de datos MySQL.